Datenanalyse mit R mosaic und ggformula

Karsten Lübke

2019-04-02

Vorbemerkungen

- R unterscheidet zwischen Groß- und Kleinbuchstaben
- R verwendet den Punkt `.` als Dezimaltrennzeichen
- Fehlende Werte werden in R durch `NA` kodiert
- Eine Ergebniszuweisung erfolgt über `<-`
- Hilfe zur Funktion `foo`: `?foo`

Innerhalb von `mosaic`:

```
analysiere(y ~ x | z , data = Daten)
```

d. h., modelliere `y` in Abhängigkeit von `x` getrennt bzw. bedingt für `z` aus dem Datensatz `Daten`.[1]

Zusatzpakete müssen vor der ersten Benutzung einmalig installiert und geladen werden:

```
# Einmalig installieren
install.packages("mosaic")
# Laden, einmalig in jeder Sitzung
library(mosaic)
```

Daten

Einlesen

```
getwd() # Aktuelles Arbeitsverzeichnis
# csv Datensatz einlesen
Daten <- read.csv2("Pfad/Datei")
# xlsx Datensatz einlesen
library(readxl) # Paket zum xlsx Import
Daten <- read_excel("Pfad/Datei")
```

Datenhandling

Paket `dplyr` (mit `mosaic` geladen)

```
filter()    # Beobachtungen filtern
select()    # Variablen wählen
mutate()    # Variablen verändern/ erzeugen
summarise() # Beobachtungen zusammmenfassen
group_by()  # Beobachtungen gruppieren
case_when() # Fallunterscheidung
%>%         # Übergabe von Ergebnissen
```

Logik

```
== ; != # Gleichheit bzw. Ungleichheit
> ; >= ; <= ; < # größer bzw. kleiner (gleich)
& ; | # und bzw. oder
```

Arithmetik

```
+ ; -  ; * ; : # Grundrechenarten
^ ; sqrt(x) # Potenz bzw. Quadratwurzel
exp(x) ; log(x) # e^x bzw. ln(x)
abs(x) # Absolutbetrag
```

Datenanalyse

Grafische Verfahren

```
gf_bar()        # Säulendiagramm
gf_histogram()  # Histogramm
gf_boxplot()    # Boxplot
gf_point()      # Streudiagrmm
mosaicplot()    # Mosaikplot (nicht ggformula)
```

Kennzahlen

```
inspect()  # Datenübersicht
tally()    # Tabellierung, Häufigkeiten
prop()     # Anteile
diffprop() # Differenz zweier Anteile
favstats() # Kennzahlübersicht
mean()     # Arithmetischer Mittelwert
diffmean() # Differenz zweier Mittelwerte
cor()      # Korrelationskoefizient
```

Verteilungen, Simulation

Normalverteilung

```
xpnorm() # Verteilungsfunktion Normalverteilung
xqnorm() # Quantilsfunktion Normalverteilung
gf_qq() # QQ-Plot (allgemein)
```

Randomisierung, Simulationen

```
set.seed() # Zufallszahlengenerator setzen
rflip()    # Münzwurf
do() *     # Wiederholung (Schleife)
sample()   # Stichprobe ohne Zurücklegen
resample() # Stichprobe mit Zurücklegen
shuffle()  # Permutation
```

Inferenz / Modellierung

Testverfahren

```
prop.test()   # Binomialtest (approximativ)
xchisq.test() # Chi-Quadrat Unabhängigkeitstest
t.test()      # t-Test
aov()         # Varianzanalyse
```

Modellierung

```
lm()                       # Lineare Regression
glm(, family="binomial") # Logistische Regression
plotModel()                # Modell zeichnen
residuals()                # Residuen
fitted()                   # Angepasste Werte
predict()                  # Vorhersagen
```

[1] Beim Mac ist `~` die Tastenkombination `alt+n`, `|` die Tastenkombination `alt+7`

Beispielanalyse

Vorbereitung

```
library(mosaic)    # mosaic laden
data(KidsFeet)     # Interner Datensatz
## ?KidsFeet          # Hilfe zum Datensatz
inspect(KidsFeet) # Datenübersicht
```

Eine kategoriale Variable

```
gf_bar( ~ domhand, data = KidsFeet)
tally( ~ domhand, data = KidsFeet)
prop( ~ domhand, success = "L", data = KidsFeet)
```

Eine metrische Variable

```
gf_histogram( ~ length, data = KidsFeet)
favstats(~ length, data = KidsFeet)
```

Zwei kategoriale Variablen

```
mosaicplot(domhand ~ biggerfoot, data = KidsFeet)
tally(biggerfoot ~ domhand, data = KidsFeet)
xchisq.test(biggerfoot ~ domhand, data = KidsFeet)
```

Zwei numerische Variablen

```
gf_point(width ~ length, data = KidsFeet)
cor(width ~ length, data = KidsFeet)
cor.test(width ~ length, data = KidsFeet)
```

Zwei Stichproben: kategorial

```
gf_bar( ~ domhand | sex, data = KidsFeet)
prop(domhand ~ sex, success = "L",
     data = KidsFeet)
prop.test(domhand ~ sex, success = "L",
          data = KidsFeet)
```

Zwei Stichproben: numerisch

```
gf_histogram( ~ length | sex, data = KidsFeet)
gf_boxplot(length ~ sex, data = KidsFeet)
favstats(length ~ sex, data = KidsFeet)
t.test(length ~ sex, data = KidsFeet)
```

Lineare Regression

```
erglm <- lm(width ~ length + sex, data = KidsFeet)
plotModel(erglm)
summary(erglm)
```

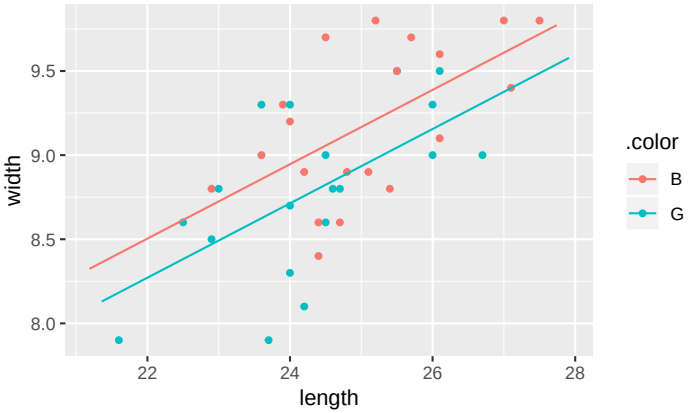

Bootstrap[2]

```
set.seed(1896)
Bootvtlg <- do(10000) *
  mean(~ length, data = resample(KidsFeet))
gf_histogram( ~ mean, data = Bootvtlg)
```

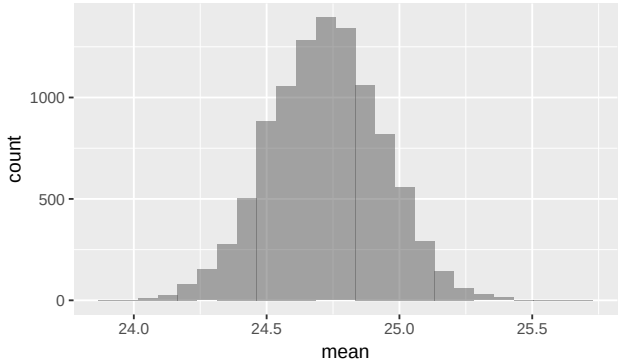


```
# Bootstrap Konfidenzintervall
quantile( ~ mean, probs = c(0.025, 0.975),
          data = Bootvtlg)
```

```
##     2.5%    97.5%
## 24.30513 25.13333
```

Permutationstest

```
set.seed(1896)
mdiff <- diffmean(length ~ sex, data = KidsFeet)
Nullvtlg <- do(10000) *
  diffmean(length ~ shuffle(sex), data = KidsFeet)
gf_histogram( ~ diffmean, data = Nullvtlg) %>%
  gf_vline(xintercept = mdiff)
```

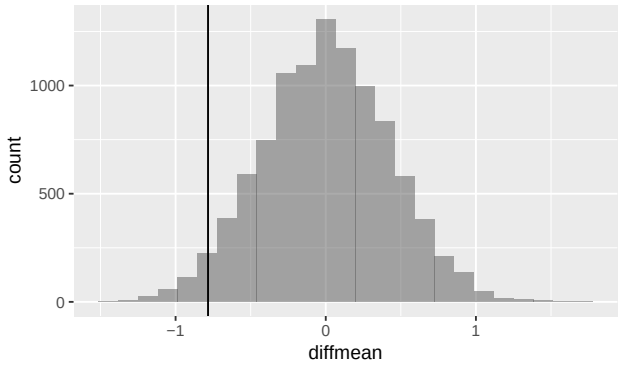


```
# Permutationstest p-Wert
prop( ~ abs(diffmean)>=abs(mdiff), data = Nullvtlg)
```

```
## prop_TRUE
##    0.0646
```

[2] Datensatz hier eher zu klein für Bootstrap Perzentile

Logistische Regression

```
ergglm <- glm(sex ~ length, family = binomial,
              data = KidsFeet)
plotModel(ergglm)
summary(ergglm)
# Odds Ratio
exp(coef(ergglm))
```

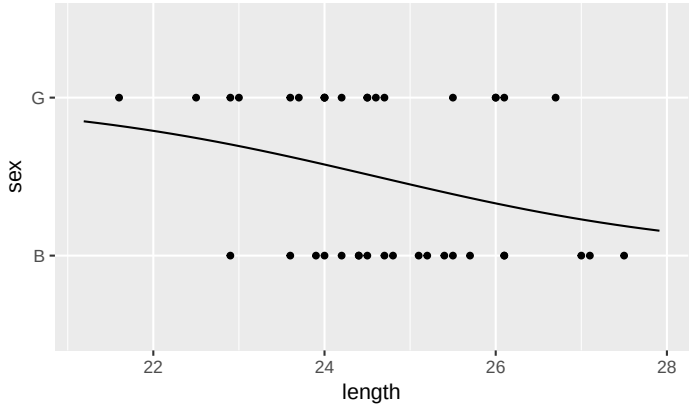

–>

–>

Zeitreihenzerlegung[3]

```
library(forecast) # Paket forecast laden
data(wineind)     # Interner Datensatz
?wineind          # Hilfe zum Datesatz
plot(wineind)
# Zerlegung
ergstl <- stl(wineind, s.window = 11)
plot(ergstl)
# Vorhersagen
predstl <- predict(ergstl)
plot(predstl)
```

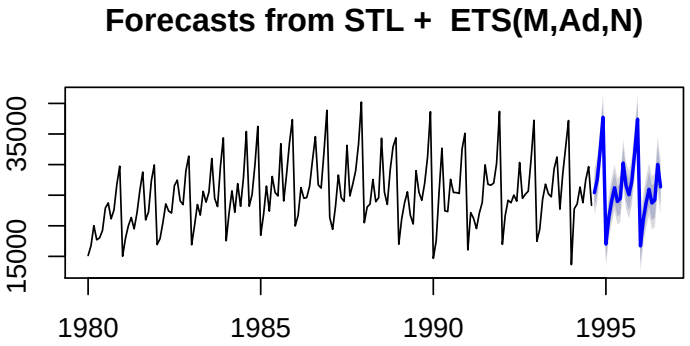

Datenhandling

```
# Variablen selektieren
KidsFeet.length <- KidsFeet %>%
  select(length)
# Beobachtungen auswählen
KidsFeet.boys <- KidsFeet %>%
  filter(sex == "B")
# Variablen erzeugen
KidsFeet.in <- KidsFeet %>%
  mutate(length.in = 0.394*length)
# Bedingungen
KidsFeet.grouped <- KidsFeet %>%
  mutate(length.grouped = case_when(
    length > 25 ~ "large",
    length <= 25 ~ "not large"))
```

- R Version: 3.5.3
- `mosaic` Version: 1.5.0

[3] Anderer Beispieldatensatz.