# Datenanalyse mit R mosaic und ggformula

Karsten Lübke

2020-03-05

## Vorbemerkungen

- R unterscheidet zwischen Groß- und Kleinbuchstaben
- R verwendet den Punkt `.` als Dezimaltrennzeichen
- Fehlende Werte werden in R durch `NA` kodiert
- Eine Ergebniszuweisung erfolgt über `<-`
- Hilfe zur Funktion `foo`: `?foo`

Innerhalb von `mosaic`:

```
analysiere(y ~ x | z , data = Daten)
```

d. h., modelliere `y` in Abhängigkeit von `x` getrennt bzw. bedingt für `z` aus dem Datensatz `Daten`.[1]

Zusatzpakete müssen vor der ersten Benutzung einmalig installiert und geladen werden:

```
# Einmalig installieren
install.packages("mosaic", type = "binary")
# Laden, einmalig in jeder Sitzung
library(mosaic)
```

## Daten

Einlesen:

```
getwd() # Aktuelles Arbeitsverzeichnis
# csv Datensatz einlesen
Daten <- read.csv2("Pfad/Datei")
# xlsx Datensatz einlesen
library(readxl) # Paket zum xlsx Import
Daten <- read_excel("Pfad/Datei")
```

Datenhandling mit Paket `dplyr` (mit `mosaic` geladen):

```
filter()        # Beobachtungen filtern
select()        # Variablen wählen
mutate()        # Variablen verändern/ erzeugen
summarise()     # Beobachtungen zusammmenfassen
group_by()      # Beobachtungen gruppieren
case_when()     # Fallunterscheidung
%>%             # Übergabe von Ergebnissen
```

Logik:

```
== ; !=         # Gleichheit bzw. Ungleichheit
> ; >= ; <= ; < # größer bzw. kleiner (gleich)
& ; |           # und bzw. oder
```

Arithmetik:

```
+ ; -  ; * ; :  # Grundrechenarten
^ ; sqrt(x)     # Potenz bzw. Quadratwurzel
exp(x) ; log(x) # e^x bzw. ln(x)
abs(x)          # Absolutbetrag
```

## Datenanalyse

Grafische Verfahren:

```
gf_bar()        # Säulendiagramm
gf_histogram()  # Histogramm
gf_boxplot()    # Boxplot
gf_point()      # Streudiagrmm
mosaicplot()    # Mosaikplot (nicht ggformula)
```

Kennzahlen:

```
inspect()       # Datenübersicht
tally()         # Tabellierung, Häufigkeiten
prop()          # Anteile
diffprop()      # Differenz zweier Anteile
favstats()      # Kennzahlübersicht
mean()          # Arithmetischer Mittelwert
diffmean()      # Differenz zweier Mittelwerte
cor()           # Korrelationskoefizient
```

## Verteilungen, Simulation

Normalverteilung:

```
xpnorm()  # Verteilungsfunktion Normalverteilung
xqnorm()  # Quantilsfunktion Normalverteilung
gf_qq()   # QQ-Plot (allgemein)
```

Randomisierung, Simulationen:

```
set.seed()    # Zufallszahlengenerator setzen
rflip()       # Münzwurf
do() *        # Wiederholung (Schleife)
sample()      # Stichprobe ohne Zurücklegen
resample()    # Stichprobe mit Zurücklegen
shuffle()     # Permutation
```

## Modellierung

```
lm()                        # Lineare Regression
glm(, family="binomial")    # Logistische Regression
plotModel()                 # Modell zeichnen
residuals()                 # Residuen
fitted()                    # Angepasste Werte
predict()                   # Vorhersagen
```

## Inferenz

```
prop.test()   # Binomialtest (approximativ)
xchisq.test() # Chi-Quadrat Unabhängigkeitstest
t.test()      # t-Test
aov()         # Varianzanalyse
```

[1] Beim Mac ist `~` die Tastenkombination `alt+n`, `|` die Tastenkombination `alt+7`

**Beispielanalyse**

Vorbereitung:

```
library(mosaic)      # mosaic laden
data(KidsFeet)       # Interner Datensatz
?KidsFeet            # Hilfe zum Datensatz
inspect(KidsFeet)    # Datenübersicht
```

Eine kategoriale Variable:

```
gf_bar( ~ domhand, data = KidsFeet)
tally( ~ domhand, data = KidsFeet)
prop( ~ domhand, success = "L", data = KidsFeet)
```

Eine metrische Variable:

```
gf_histogram( ~ length, data = KidsFeet)
favstats(~ length, data = KidsFeet)
```

Zwei kategoriale Variablen:

```
mosaicplot(domhand ~ biggerfoot, data = KidsFeet)
tally(biggerfoot ~ domhand, data = KidsFeet)
xchisq.test(biggerfoot ~ domhand, data = KidsFeet)
```

Zwei numerische Variablen:

```
gf_point(width ~ length, data = KidsFeet)
cor(width ~ length, data = KidsFeet)
cor.test(width ~ length, data = KidsFeet)
```

Zwei Stichproben: kategorial:

```
gf_bar( ~ domhand | sex, data = KidsFeet)
prop(domhand ~ sex, success = "L",
     data = KidsFeet)
prop.test(domhand ~ sex, success = "L",
          data = KidsFeet)
```

Zwei Stichproben: numerisch:

```
gf_histogram( ~ length | sex, data = KidsFeet)
gf_boxplot(length ~ sex, data = KidsFeet)
favstats(length ~ sex, data = KidsFeet)
t.test(length ~ sex, data = KidsFeet)
```

Lineare Regression:

```
erglm <- lm(width ~ length + sex,
            data = KidsFeet)
plotModel(erglm)
summary(erglm)
```

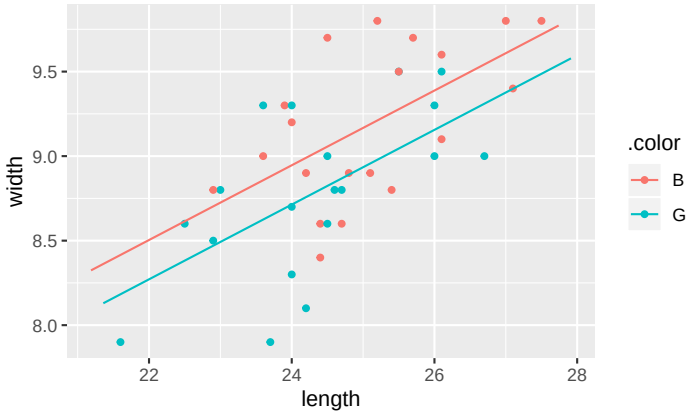


Logistische Regression:

```
ergglm <- glm(sex ~ length, family = binomial,
              data = KidsFeet)
plotModel(ergglm)
summary(ergglm)
# Odds Ratio
exp(coef(ergglm))
```

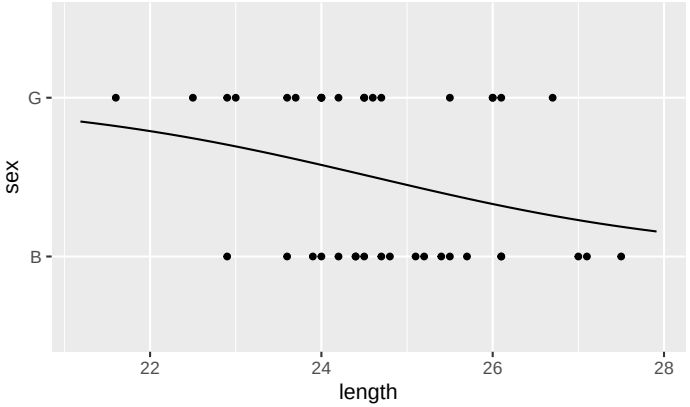


Datenhandling:

```
# Variablen selektieren
KidsFeet.length <- KidsFeet %>%
  select(length)
# Beobachtungen auswählen
KidsFeet.boys <- KidsFeet %>%
  filter(sex == "B")
# Variablen erzeugen
KidsFeet.in <- KidsFeet %>%
  mutate(length.in = 0.394*length)
# Bedingungen
KidsFeet.grouped <- KidsFeet %>%
  mutate(length.grouped = case_when(
    length > 25 ~ "large",
    length <= 25 ~ "not large"))
```

Bootstrap:[2]

```
set.seed(1896)
# Simuliere Ziehen zufälliger Stichprobe
Bootvtlg <- do(10000) *
  mean(~ length, data = resample(KidsFeet))
# Bootstrap-Verteilung
gf_histogram( ~ mean, data = Bootvtlg)
```

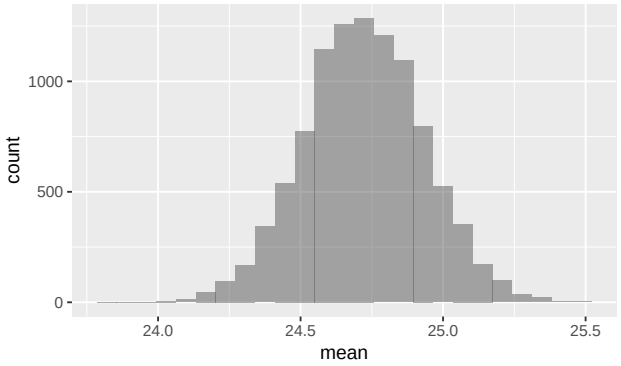


```
# Bootstrap Konfidenzintervall
confint(Bootvtlg)
```

```
##   name    lower   upper level     method estimat
## 1 mean 24.31019 25.1334  0.95 percentile 24.723(
```

Permutationstest:

```
set.seed(1896)
# Beobachtete Differenz
est.diff <- diffmean(length ~ sex,
                     data = KidsFeet)
# Simuliere zufällige Zuordnung:
Nullvtlg <- do(10000) *
  diffmean(length ~ shuffle(sex),
           data = KidsFeet)
# Verteilung unter H_0
gf_histogram( ~ diffmean, data = Nullvtlg) %>%
  gf_vline(xintercept =~ est.diff)
```

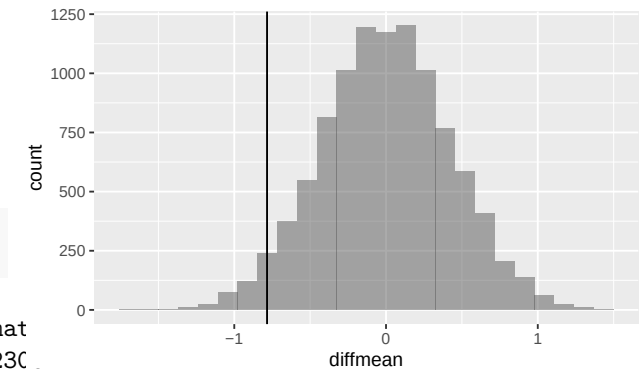


```
# Permutationstest p-Wert
prop( ~ abs(diffmean) >= abs(est.diff),
      data = Nullvtlg)
```

```
## prop_TRUE
##     0.066
```

---


- R Version: 3.6.3
- `mosaic` Version: 1.5.0

[2] Datensatz hier eher zu klein für Bootstrap Perzentile